

Compressão de Vocalizações de Anuros para Classificação de Espécies Usando Redes de Sensores Sem Fio

Javier J. M. Diaz¹, Juan G. Colonna¹, Rodrigo B. Soares¹
Eduardo F. Nakamura^{1,2}, Carlos M. S. Figueiredo²

¹Departamento de Ciência da Computação (DCC)
Universidade Federal do Amazonas (UFAM)

²Núcleo de Estudos e Pesquisas em Computação (NEPComp)
Fundação Centro de Análise, Pesquisa e Inovação Tecnológica (FUCAPI)

{jjmd90, juancolonna, rborges.soares}@gmail.com

{eduardo.nakamura, mauricio.figueiredo}@fucapi.br

Abstract. *One of the most common problems in Wireless Sensor Networks (WSN) is to collect enough data to analyze some phenomenon and to maximize the network lifetime. By using an anura (frogs and toads) classification example, this paper shows how it is possible to significantly decrease the amount of samples collected without compromising the classification results. To do that, is proposed a methodology using Compressive Sensing (CS) that allows partially collected signal reconstruction. This is done by using a sparse basis that best represents the information used by the classifying software. We show how it is possible to keep a classification rate near to 98% using only 10% of the original data, beside the impact of this compression on the energy consumption, delivery rate and average delay of the network*

Resumo. *Um dos problemas mais comuns em redes de sensores sem fio (RSSF) é coletar dados suficientes para analisar um determinado fenômeno maximizando o tempo de vida da rede. Utilizando o exemplo de classificação de anuros (sapos e rãs), este trabalho mostra como é possível reduzir a quantidade de amostras coletadas sem comprometer a precisão da classificação. Para isso, é proposta uma metodologia utilizando Compressive Sensing (CS) que permite a reconstrução de sinais parcialmente coletados. Isto é feito mediante a utilização de uma base esparsa que melhor represente as informações usadas pelo classificador. Mostramos como é possível manter uma taxa de classificação de cerca de 98% utilizando apenas 10% da informação original, além do impacto desta compressão no consumo de energia, na taxa de entrega e no atraso médio da rede.*

1. Introdução

Redes de sensores sem fio (RSSF) vêm sendo cada vez mais utilizadas em aplicações de monitoramento ambiental [Wang et al. 2011]. Mediante o monitoramento de determinados ambientes ou espécies é possível obter informações úteis para o entendimento e a preservação do ecossistema no qual a RSSF se encontra [Mainwaring et al. 2002]. Entretanto, ainda existem muitas limitações no que diz respeito ao tempo de vida desse tipo

de redes, pois são alimentadas por baterias de curta duração [Gowrishankar et al. 2008, Rocha and Gonçalves 2008].

O monitoramento de anuros é de grande utilidade nos campos da Ecologia e Biologia, pois estes servem de referência para avaliar a qualidade do ambiente no qual vivem [Carey et al. 2001b]. No entanto, aplicações de classificação de anuros captam do meio mais informação que a necessária pelo classificador [Colonna et al. 2011], gerando sobrecarga de tráfego e consumo desnecessário de energia.

Utilizando técnicas de Compressive Sensing (CS) é possível diminuir a quantidade de amostras coletadas de um determinado sinal, para reconstruí-lo posteriormente. Para isso, basta que o sinal seja representável em uma base esparsa [Candes and Waking 2008, Ji and Carin 2007]. Em RSSF a quantidade de amostras está diretamente relacionada ao consumo de energia da rede, assim como a quantidade de pacotes que trafegam pela mesma [Hempstead and Yang 2006].

Utilizando o classificador de anuros proposto em [Colonna et al. 2011] este trabalho mostra como é possível diminuir em até 90% a quantidade de amostras captadas e enviadas pela RSSF sem comprometer os resultados de classificação. Mediante a análise bioacústica das espécies, foi construída uma base esparsa que garante a reconstrução do áudio utilizando técnicas de CS. Além disso, o impacto da técnica em uma RSSF foi avaliado mediante simulações feitas no Network Simulator 2 (NS-2).

O restante deste trabalho apresenta-se como segue. A seção 2 mostra os fundamentos e trabalhos relacionados. A seção 3 explica a metodologia adotada nos experimentos de CS. A seção 4 mostra o cenário de simulação adotado para representar a RSSF. Na seção 5 são apresentados os experimentos e, os resultados obtidos. Por último, a seção 6 apresenta as conclusões e propostas de trabalhos futuros.

2. Fundamentos e Trabalhos Relacionados

2.1. *Compressive Sensing*

A abordagem mais comum para coleta de sinais é seguir o teorema de Shannon, onde a taxa de amostragem deve ser no mínimo o dobro da frequência máxima presente no sinal [Candes and Waking 2008]. Graças a técnicas de Compressive Sensing (CS) é possível recuperar certos sinais com uma quantidade de amostras muito menor que a utilizada por métodos tradicionais [Luo et al. 2010, Ji and Carin 2007, Ji et al. 2009].

CS pode ser aplicado sempre que o sinal a ser reconstruído tiver duas propriedades básicas: esparsidade e independência linear (ou incoerência) [Candes and Waking 2008]. Uma vez garantida a esparsidade e a independência linear do sinal, é necessário gerar uma base ψ com componentes independentes do mesmo [Baraniuk 2007] para utilizá-la durante a reconstrução.

Uma das aplicações mais conhecidas de CS é a sua utilização em equipamentos de ressonância magnética. Os aparelhos de ressonância magnética tem um alto custo de amostragem (em energia e tempo) e as imagens por eles geradas podem ser representadas em bases esparsas [Aelterman et al. 2010]. A qualidade da reconstrução de CS é necessária, principalmente em aplicações de caráter médico [Zamani et al. 2011]. Graças à aplicação de CS neste tipo de aparelhos, o tempo de amostragem diminuiu de horas para apenas alguns segundos [Zamani et al. 2011, Aelterman et al. 2010].

A aplicação de Compressive Sensing em processamento de imagens também é muito comum [Baraniuk 2007, Ji and Carin 2007]. Em [Ji and Carin 2007] são feitas reconstruções de obras de arte de Mondrian utilizando métodos de Bayesian compressive Sensing (BCP). [Ji and Carin 2007] mostra uma melhoria de 89% no tempo de reconstrução mantendo um erro de até 16% em relação a técnicas de reconstrução normais.

Trabalhos como [Carin et al. 2011, Candes and Waking 2008] mostram aplicações diretas de CS na reconstrução de fotografias e técnicas para utilizar CS para a separação de componentes de uma imagem como, por exemplo, uma parte estática (background) de uma parte móvel (foreground), mediante a captação de imagens consecutivas. Além disso, [Candes and Waking 2008] mostra como é possível aplicar a mesma metodologia a sinais de áudio gerados randomicamente utilizando amostragem parcial, seguida de reconstrução via minimização ℓ_1 . A metodologia proposta em [Candes and Waking 2008] é muito similar à utilizada neste trabalho. Entretanto, em vez de utilizar sinais gerados randomicamente, este trabalho utiliza vocalizações reais captadas de anuros presentes na natureza.

2.2. Classificação de Anuros

Devido à íntima relação com seu habitat, os anuros são considerados como métrica de avaliação dos impactos ambientais em uma determinada região [Carey et al. 2001a]. Entretanto, a tarefa de encontrar e classificar anuros diretamente no seu habitat não é trivial.

A classificação dos anuros pode ser feita de forma manual [Riede 1993], mediante a análise de gravações e seus espectros por especialistas, ou de forma automática [Hu et al. 2005, Huang et al. 2009, Colonna et al. 2011], utilizando RSSF como suporte para a captação e processamento de dados.

Quando feita de forma manual, a qualidade da classificação de anuros está relacionada à experiência do especialista que a realiza [Colonna et al. 2011], podendo se tornar um processo lento e ineficiente. Entretanto, apesar das técnicas automáticas serem mais rápidas e precisas que a análise manual, a quantidade de informação utilizada para a classificação gera um impacto de desempenho na RSSF, como será mostrado mais adiante.

Os resultados de classificação utilizando meios automáticos variam entre 50% em [Taylor et al. 1996], 82,6% em [Huang et al. 2009] e 99,3% em [Colonna et al. 2011]. A grande diferença entre os resultados deve-se principalmente às informações utilizadas como base para a classificação. [Taylor et al. 1996] utiliza a intensidade dos pixels do espectrograma das gravações como referência para fazer a classificação. Uma vez avaliada a intensidade de cada pixel e seus vizinhos, foi utilizada uma árvore de decisão C4.5 para fazer a classificação.

Trabalhos como [Huang et al. 2009] e [Colonna et al. 2011] dividem o áudio captado em segmentos chamados sílabas. Estes segmentos são considerados a menor unidade de vocalização de um anuro, contendo assim as informações mais importantes para sua classificação.

Em [Huang et al. 2009] a classificação é feita utilizando técnicas de *k-Nearest Neighbor* (*kNN*) e *Support Vector Machine* (*SVN*), utilizando as sílabas como referência. Já [Colonna et al. 2011] acrescenta a utilização de *Mel-Fourier Cepstral Coefficient* (*MFCCs*) para melhorar os resultados. MFCCs são conhecidos por serem amplamente

utilizados em reconhecimento de fala [Davis and Mermelstein 1980], . Por possuir melhores resultados em termos de classificação, este trabalho usa como base a técnica proposta por [Colonna et al. 2011] . No entanto, em vez de utilizar as gravações completas como entrada para o classificador, a quantidade de informação utilizada é reduzida em até 90%.

2.3. Gradient Projection for Sparse Reconstruction (GPSR)

Para realizar a reconstrução dos sinais neste trabalho foi utilizado um método para reconstrução esparsa mediante projeção de gradientes (GPSR) [Figueiredo et al. 2007]. O método proposto em [Figueiredo et al. 2007] toma como base o problema de otimização abaixo:

$$\min_x = \frac{1}{2} \| \mathbf{y} - \mathbf{A}\mathbf{x} \|_2^2 + \tau \|\mathbf{x}\|_1 \quad (1)$$

Onde $\mathbf{x} \in R^n$, $\mathbf{y} \in R^k$, \mathbf{A} é uma matriz $k \times n$, τ é um parâmetro positivo, $\|v\|_2$ é a norma Euclidiana de v e $\|v\|_1 = \sum_i |v_i|$ é a norma ℓ_1 de v . Este tipo de problema é muito comum na área de processamento de sinais e está diretamente relacionado à estimativa de de observações em um sistema do tipo:

$$\mathbf{y} = \mathbf{A}\mathbf{x} + n \quad (2)$$

A presença do termo ℓ_1 na Equação 1 faz com que os menores componentes de x na Equação 2 tendam a zero, fazendo com que as soluções obtidas sejam esparsas, sendo este tipo de abordagem ideal para problemas de CS.

O algoritmo proposto em [Figueiredo et al. 2007] implementa uma solução para o problema mostrado na Equação 1 que permite a reconstrução de sinais de áudio e imagens através de um método iterativo de aproximação. O grande diferencial deste método é a aplicação de uma etapa onde é feito o *debiasing* da aproximação, garantindo que qualquer viés de cálculo seja removido. Desta forma é possível obter uma solução mais próxima da solução ideal.

3. Metodologia

3.1. Captação e análise dos áudios

Para a realização dos experimentos deste trabalho foram utilizadas amostras de áudio captadas diretamente na natureza de quatro espécies de anuros. Por razões computacionais, as amostras coletadas foram divididas em arquivos de 10 segundos de áudio e todo o processo de reconstrução foi feito em cima destes novos arquivos parciais. Foram coletados entre 30 a 50 MB de áudio de cada espécie, totalizando 5 minutos de gravação em arquivos do tipo *.wav*.

Como foi visto na Seção 2.1, para reconstruir algum sinal baseado em uma amostragem esparsa do mesmo, é necessário definir uma base de reconstrução que possua as principais características desse sinal. Em se tratando de classificação de anuros, as características dos sinais bioacústicos de cada espécie são um fator suficientemente representativo para fazer a classificação das mesmas [Colonna et al. 2011, Huang et al. 2009].




Figura 1. Vocalizações da espécie *Adenomera andreae*




Figura 2. Espectrograma da espécie *Adenomera andreae*




Figura 3. Taxa de ocorrência de frequências com a aplicação da Transformada de Fourier (FFT) da espécie *Adenomera andreae*

Para realizar a extração das características de cada espécie monitorada foi feita uma separação inicial das sílabas de cada uma delas. Como pode ser visto na Figura 1, as vocalizações são compostas por picos, seguidas de um momento de repouso. No entanto, como pode ser visto na Figura 2, apesar das frequências fundamentais da espécie apresentarem maior intensidade nos picos, elas continuam presentes nos momentos de repouso. Com o intuito de maximizar o aproveitamento das frequências fundamentais, a separação

de sílabas neste trabalho foi feito de acordo com a Figura 1, onde são consideradas todas as frequências presentes entre o início de uma vocalização e outra.

Uma vez separadas as sílabas de cada espécie, é necessário extrair as frequências mais representativas que serão utilizadas como critério de reconstrução e de classificação dos anuros. Para separar as frequências foi aplicada uma Transformada de Fourier (FFT) nas sílabas previamente separadas e, a partir disso, foram consideradas as frequências com maior ocorrência em cada espécie. O resultado da aplicação da FFT em um conjunto de sílabas pode ser visto na Figura 3

3.2. Base de reconstrução e parâmetros experimentais

Uma vez obtidas as frequências fundamentais de cada espécie, é necessário criar uma base de reconstrução de áudio. Para realizar reconstruções em CS, recomenda-se a utilização de uma base esparsa (Seção 2.1). A base de reconstrução é a matriz **A** da Fórmula 2 que será utilizada para avaliar e reconstruir o áudio de acordo com o vetor de amostragem x da mesma fórmula.

Por se tratar de reconstrução de áudio, é necessário que a base de reconstrução represente as características de uma onda sonora. Para isso, foram geradas ondas senoidais semelhantes às emitidas nas vocalizações dos anuros e, em seguida, foram segmentadas utilizando MATLAB. Cada frequência foi convertida em uma onda e inserida como uma linha da matriz **A**, onde o tamanho de **A** é condizente com o tamanho das amostras que serão reconstruídas (10 s de áudio).

Uma vez gerada a base de reconstrução e com a utilização da implementação proposta em [Figueiredo et al. 2007], é possível reconstruir gravações de anuros utilizando como base amostragens pseudorandômicas. Para isso, é necessário definir um parâmetro α de *undersampling*. A partir de α são gerados pacotes onde apenas uma em cada α amostras disponíveis para captação são de fato captadas e enviadas pela rede. Os pacotes gerados utilizaram como base gravações completas ($\alpha = 1$), gerando novos sinais de áudio apenas com as amostras coletadas mediante o *undersampling*.

O objetivo principal das técnicas de CS é minimizar a perda de informação. Desta forma, mesmo para sinais gerados com *undersampling*, onde $\alpha > 1$, o resultado da reconstrução do sinal será equivalente (em número de amostras) a um sinal onde $\alpha = 1$.

4. Cenário de Simulação

Com o objetivo de avaliar o impacto da aplicação de CS em RSSF foram realizadas simulações utilizando o *Network Simulator 2* (NS2) para os diferentes valores de α , de acordo com a Seção 3.2.

O cenário da simulação consistiu em um grid com 625 nós (25x25). O lado de cada célula do grid foi setado para 100 metros. A fim de implementar uma simulação mais realista o grid foi perturbado, alterando randomicamente as coordenadas de cada nó em até 50 metros em ambos os eixos.

Foi definida uma posição de origem para o áudio gerado pelo anuro. Nesta posição foi colocado um nó emitindo informação para todos os nós vizinhos com um alcance variável. Para enviar a informação foi realizado um broadcast e todos os nós que captassem a mensagem a transmitem para o *sink* de acordo com o protocolo de roteamento

definido. As posições do nó gerador e do *sink* foram definidas randomicamente em cada cenário.

Para realizar o roteamento dos pacotes gerados foi utilizado o algoritmo *One-Phase Push Diffusion* (OPPD) [Cheng et al. 2008]. O protocolo OPPD consiste em duas etapas: reconhecimento e transmissão. Na etapa de reconhecimento é definida uma árvore de roteamento na qual o *sink* é o nó raiz. Na etapa de transmissão cada nó envia a informação para o seu pai até a informação chegar ao *sink*, utilizando a árvore gerada como referência.

As métricas utilizadas para avaliação do desempenho da RSSF foram: atraso médio de chegada dos pacotes, perda de pacotes e consumo de energia dos nós sensores. Para melhor entender o impacto da técnica proposta no consumo de energia, os nós foram divididos em três grupos: *sink*, nós de roteamento e os nós responsáveis por captar o áudio do anuro.

Tabela 1. Energia utilizada por um sensor MICA em diversas operações de rede/sensoriamento. Tabela adaptada de [Mainwaring et al. 2002].

| Operação | Consumo em nAh |
|----------------------------------|----------------|
| Transmitir um pacote | 20.000 |
| Receber um pacote | 8.000 |
| Capturar uma amostra (analógica) | 1.080 |
| Capturar uma amostra (digital) | 0.347 |
| Ler uma amostra do ADC | 0.011 |
| Ler EEPROM | 1.111 |
| Escrever/Apagar EEPROM | 83.333 |

A divisão dos nós em três categorias é baseada nas informações presentes na Tabela 1. Dada a arquitetura da rede, os nós captadores de áudio têm uma perda extra de energia causada por cada operação de captação. Os nós de roteamento tem o maior consumo, pois gastam energia ao receber e reenviar pacotes. Já o *sink* realiza apenas um envio (para construção da árvore de roteamento) e, no restante do processo, apenas recebe pacotes. Ainda de acordo com [Mainwaring et al. 2002], a energia inicial dos nós foi setada para 22.000 mAh.

Para testar a variabilidade do ambiente foram considerados três cenários de acordo com o alcance das vocalizações do anuro: 250 m, 300 m e 350 m. Cada cenário consiste no envio de 5 minutos de áudio (Seção 3.1) com as posições dos nós, do *sink* e do anuro setadas randomicamente. Além disso, cada cenário foi repetido em torno de 30 vezes para estabelecer uma média dos parâmetros avaliados.

5. Resultados

Ao aplicar o parâmetro α nas gravações é possível ver uma redução significativa na quantidade de informação enviada pela rede de acordo com a Figura 4. Para ter uma visão melhor do comportamento geral do parâmetro o mesmo foi variado entre $\alpha = 5$ e $\alpha = 105$.

Uma vez feito o *undersampling* das gravações realizadas, os áudios foram testados no classificador proposto em [Colonna et al. 2011] para verificar a qualidade da reconstrução. Como pode ser visto na Figura 5, apesar da redução significativa na quantidade de




Figura 4. Tamanho do pacote de áudio em relação ao parâmetro α

informação captada, a qualidade da reconstrução sofre um impacto muito baixo, estando sempre acima de 97%. Esse resultado encontra-se muito próximo aos 98,97% de precisão atingidos em [Colonna et al. 2011], com a vantagem de estar utilizando menos de 90% da informação captada.




Figura 5. Relação entre o tamanho do pacote de áudio e a classificação

Além do impacto da compressão na classificação, também foi avaliado desempenho da RSSF de acordo com os parâmetros definidos na Seção 4. O primeiro parâmetro avaliado foi o consumo de energia de acordo com a divisão feita entre os nós: *sink*, nós captadores e nós de roteamento. O *sink* teve o menor consumo de energia em relação às outras duas categorias de nós pois a única operação que executa é de recebimento, cujo custo é cerca de 36% menor que a de envio.

Como pode ser visto na Tabela 2, o consumo dos sinks (mAh) aumenta conforme o tamanho do pacote que está sendo enviado aumenta. Dessa forma, quanto maior o valor do parâmetro α , maior será a economia de energia na rede. Nas Figuras 6 e 7 é possível perceber que o consumo de energia dos nós de roteamento em relação ao sink é mais que

Tabela 2. Consumo dos Sinks (mAh) de acordo com o tamanho do pacote e o alcance das vocalizações do anuro

| Categoria | 250 m | 300 m | 350 m |
|--------------------------|--------------|--------------|--------------|
| 18 KB ($\alpha = 55$) | 5,58 | 5,54 | 4,92 |
| 180 KB ($\alpha = 5$) | 47,52 | 49,99 | 44,07 |
| 1800 KB ($\alpha = 1$) | 499,45 | 481,62 | 469,32 |

o dobro do consumo dos nós captadores. Com isso é possível concluir que a maior parte da energia da rede é consumida no roteamento de pacotes.




Figura 6. Consumo dos nós de roteamento em relação ao Sink




Figura 7. Consumo dos nós captadores em relação ao Sink

Ao avaliar o parâmetro taxa de entrega nos diversos cenários simulados, foi pos-

sível perceber que independentemente do tamanho do pacote que trafegasse pela rede, a entrega se manteve constante em torno de 18% e 20%. Já o atraso médio de entrega de pacotes apresentou um comportamento similar ao consumo de energia em relação às variações realizadas no parâmetro α como pode ser visto na Tabela 3

Tabela 3. Atraso dos pacotes (ms) de acordo com o tamanho do pacote e o alcance das vocalizações do anuro

| Categoria | 250 m | 300 m | 350 m |
|--------------------------|--------------|--------------|--------------|
| 18 KB ($\alpha = 55$) | 341,87 | 331,33 | 289,75 |
| 180 KB ($\alpha = 5$) | 4120,38 | 4398,71 | 3939,69 |
| 1800 KB ($\alpha = 1$) | 43078,46 | 44131,33 | 42135,10 |

6. Conclusões e Trabalhos Futuros

Este trabalho mostrou a viabilidade da aplicação de Compressive Sensing para classificação de anuros em redes de sensores sem fio utilizando uma abordagem prática com o auxílio de simulações. Devido à natureza do classificador desenvolvido em [Colonna et al. 2011] é possível criar uma base de reconstrução de sinais que considere as informações mais importantes para o classificador, desta forma economiza-se muitos recursos obtendo as informações necessárias para uma classificação efetiva.

O recurso mais crítico em RSSF é a energia pois este tipo de redes são muito utilizadas em ambientes hostis ou de difícil acesso, dificultando assim a troca de baterias. Foi mostrado que apesar das operações de captação de dados não serem tão custosas para o nó sensor, a quantidade de informação por ele captada gera um tráfego na rede que impacta diretamente o consumo de energia, comprometendo assim o tempo de vida da rede.

A avaliação da taxa de entrega dos pacotes na rede mostrou que a metodologia aplicada não causou um impacto significativo neste parâmetro, podendo este ser melhorado mediante a implementação de protocolos mais efetivos para gerenciar o roteamento.

O grande diferencial da aplicação de CS é a construção da base que será utilizada para reconstruir as amostragens realizadas. Ao escolher bem os parâmetros que serão utilizados nesta base, a reconstrução chega a ser quase perfeita com uma quantidade muito pequena de informação.

Entre os trabalhos futuros pretende-se estudar a possibilidade de implementar algoritmos distribuídos para maximizar a quantidade de informação obtida sem aumentar os custos. Além disso, métodos para uma construção automática da base de reconstrução, gerando assim uma rede sensível ao contexto no qual ela se encontra. Para este trabalho foram utilizadas apenas quatro espécies de anuros, podendo este número ser incrementado para validar os resultados obtidos. A construção de bases de avaliação e reconstrução de áudio de outras espécies como primatas ou aves também se apresenta como uma idéia promissora se o objetivo é desenvolver métodos de monitoramento ambiental mas efetivos e generalizados.

Referências

- Aelterman, J., Luong, H. Q., Goossens, B., Pi, A. U., and Philips, W. (2010). Compass: a joint framework for parallel imaging and compressive sensing in mri. In *Image Proceesing (ICIP)*. IEEE.
- Baraniuk, R. (2007). Compreeisive sensing. In *IEEE Signal Processing Magazine*. IEEE.
- Candes, E. J. and Waking, M. B. (2008). An introduction to compressed sampling. In *Signal Processing Magazine*. IEEE.
- Carey, C., Heyer, W. R., Wilkinson, J., a. Alford, R., Arntzen, J. W., Halliday, T., Hungerford, L., Lips, K. R., Middleton, E. M., a. Orchard, S., and Rand, S. (2001a). Amphibian declines and environmental change: Use of remote-sensing data to identify environmental correlates. In *Conservation Biology*.
- Carey, C., Wilkinson, W. R., Alford, J., Arntzen, R. A., Halliday, J. W., Hun-gerford, T., Lips, L., Middleton, K. R., M., E., Orchard, S. A., and Rand (2001b). Amphibian declines and environmental change: Use of remote-sensing data to identify environmental correlates. In *Conservation Biology*. Mendeley.
- Carin, L., Ding, X., and He, L. (2011). Bayesian robust principal component analysis. In *IEEE Transactions on Image Processing*. IEEE.
- Cheng, X., Wang, F., and Liu, J. (2008). Hybrid push-pull for data diffusion in sensor networks without location information. In *International Conference on Communications (ICC)*. IEEE.
- Colonna, J. G., Nakamura, E. F., and dos Santos, E. M. (2011). Classificação de anuros baseado em vocalizações para monitoramento ambiental pervasivo. In *Simpósio Brasileiro de Computação Ubíqua (SBCUP)*. SBRC.
- Davis, S. and Mermelstein, P. (1980). Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. In *IEEE Transactions on Acoustics, Speech, and Signal Processing*. IEEE.
- Figueiredo, M. A. T., Nowak, R. D., and Wright, S. J. (2007). Gradient projection for sparse reconstruction: Application to compressed sensing and other inverse problems. In *IEEE Journal of Selected Topics in Signal Processing*. IEEE.
- Gowrishankar, S., Basavaraju, T. G., Manjaiah, D. H., and Sarkar, S. K. (2008). Issues in wireless sensor networks. In *Proceedings of the World Congress on Engineering*. WCE.
- Hempstead, Q. W. and Yang, M. (2006). A realistic power consumption model for wireless sensor network devices. In *Sensor and Ad Hoc Communications and Networks (SECON)*. IEEE.
- Hu, W., Tran, V. N., Bulusu, N., Chou, C. T., Jha, S., and Taylor, A. (2005). The design and evaluation of a hybrid sensor network for cane-toad monitoring. In *Symposium on Information Processing in Sensor Networks*.
- Huang, J. C., Yang, Y. J., Yang, D. X., and Chen, J. Y. (2009). Frog classification using machine learning techniques. In *Expert Systems with Applications*.

- Ji, S. and Carin, L. (2007). Bayesian compressive sensing and projection optimization. In *International Conference on Machine Learning (ICML)*. ACM.
- Ji, S., Dunson, D., and Carin, L. (2009). Multi-task compressive sensing. In *IEEE Transactions on Signal Processing*. IEEE.
- Luo, J., Xiang, L., and Rosenberg, C. (2010). Does compressed sensing improve the throughput of wireless sensor networks? In *IEEE International Conference on Communications (ICC)*. IEEE.
- Mainwaring, A., Polastre, J., Szewczyk, R., and Culler, D. (2002). Wireless sensor networks for habitat monitoring. In *Proceedings of the 1st ACM international workshop on Wireless sensor networks and applications*. ACM.
- Riede, K. (1993). Monitoring biodiversity: analysis of amazonian rainforest sounds. In *Ambio*.
- Rocha, V. and Gonçalves, G. (2008). Sensing the world: Challenges on wsns. In *Automation, Quality and Testing, Robotics. (AQTR)*. IEEE.
- Taylor, A., Watson, G., Grigg, G., and a. McCallum, H. (1996). Monitoring frog communities: An application of machine learning. In *Proceedings of the 8th Innovative Applications of Artificial Intelligence Conference (IAAI)*. AAAI.
- Wang, J., Cho, J., and Lee, S. (2011). An adaptive power-aware multi-hop routing algorithm for wireless sensor networks. In *Information Technology: New Generations (ITNG)*. IEEE.
- Zamani, P., Kayvanrad, M. H., and Soltanian-Zadeh, H. (2011). Cardiac cine mri using compressive sensing principles. In *Biomedical Engineering (ICBME)*. IEEE.